

Reconhecimento e análise de doenças na pele com uso de Machine Learning

Gabriel Augusto T. Azevedo, Guilherme Pasiani de Paula, Lucas
Kenzo Akiyama, Rogerio de Oliveira

Faculdade de Computação e Informática — Universidade Presbiteriana
Mackenzie (UPM) — São Paulo — SP — Brasil

{32020309, 32078358, 32025165}@mackenzista.com.br

rogerio.oliveira@mackenzie.br

Abstract. *This study addresses melanoma, a dangerous skin cancer, highlighting the importance of early diagnosis. Explores the complexity of clinical analysis of skin lesions and highlights the use of image processing techniques and artificial neural networks. We use an efficient neural network model, based on pre-trained ResNet-50, capable of classifying dermatological images of skin diseases. The approach includes concatenating the ResNet-50 model with a Convolutional Neural Network and relevant metadata, aiming to detect skin cancer. Resulting in excellent performance and contributing significantly to advances in the medical field.*

Keywords: *Melanoma, skin cancer, skin lesions, ResNet, deep neural network, neural network*

Resumo. *Este estudo aborda o melanoma, um câncer de pele perigoso, destacando a importância do diagnóstico precoce. Explora a complexidade da análise clínica das lesões cutâneas e destaca a utilização de técnicas de processamento de imagens e redes neurais artificiais. Utilizamos um modelo de rede neural eficiente, baseado em ResNet-50 pré-treinado, capaz de classificar imagens dermatológicas de doenças de pele. A abordagem inclui a concatenação do modelo ResNet-50 com uma Rede Neural Convolutiva e metadados relevantes, visando a detecção do câncer de pele. Resultando em um desempenho excelente e contribuindo significativamente para avanços na área médica.*

Palavras-chave: *Melanoma, câncer de pele, lesões de pele, ResNet, rede neural profunda*

1. INTRODUÇÃO

O melanoma é um tipo de câncer de pele que pode apresentar um alto grau de agressividade e mortalidade se não diagnosticado e tratado precocemente. A detecção precoce é crucial para o sucesso do tratamento, mas pode ser desafiadora devido à complexidade da análise clínica das lesões cutâneas. Nesse sentido, as técnicas de processamento de imagens, combinadas com o uso de redes neurais artificiais, têm sido uma ferramenta promissora para auxiliar no diagnóstico de melanoma, contribuindo diretamente para o avanço da área médica e para o diagnóstico precoce de câncer de pele.

De acordo com a Organização Mundial da Saúde (OMS), cerca de 132 mil casos de melanoma, um dos tipos mais agressivos de câncer de pele, são diagnosticados todos os anos globalmente. A detecção precoce é fundamental para aumentar as chances de cura e melhorar o prognóstico dos pacientes. No entanto, a detecção do melanoma pode ser um desafio para dermatologistas, pois exige uma análise minuciosa das características das lesões e diferenciação com outras lesões benignas.

Conforme o estudo publicado pelo Ministério da Saúde e o Instituto Nacional de Câncer José Alencar Gomes da Silva, no Brasil, a estimativa de casos para não melanomas esperados para os anos de 2023 a 2025 varia em torno de 220.490, sendo 101.920 para homens e 118.570 para mulheres, quanto aos melanomas, foram estimados 8.980 sendo 4.600 novos casos para homens e 4.400 para mulheres, além disso, alguns outros fatores podem influenciar ainda mais no aumento desses acontecimentos, sendo a principal delas as diferenças nas regiões brasileiras. No Sul, o câncer de pele melanoma e não melanoma são mais incidentes comparado a outras regiões do país devido a cor de pele clara, já nos outros estados existem mais ocorrências de não melanomas, ocasionando cerca de 2653 óbitos anuais.

A fim de conseguir contribuir para a detecção prévia da doença, desenvolveu-se um modelo utilizando ResNet-50 para classificação de doenças de pele e utilizando uma *Convolutional Neural Network* comum para concatenação através do modelo tabular, juntamente a implementação de informações cruciais nas imagens com intuito de providenciar um diagnóstico adicional.

2. REFERENCIAL TEÓRICO

A partir da última década, considerando a relevância da identificação do melanoma, têm sido empregados mecanismos para automatizar esse processo, através do aprendizado de máquina. Dentre esses trabalhos, o uso da aprendizagem profunda tem se evidenciado como uma das estratégias promissoras para o progresso no auxílio à detecção de melanomas pelos profissionais médicos.

Dentre os trabalhos analisados como base para o nosso referencial, destaca-se o trabalho "*Skin lesion classification of dermoscopic images using machine learning and convolutional neural network*" que aborda a identificação de doenças perigosas relacionadas à pele, principalmente o câncer, por meio do reconhecimento de lesões pigmentadas. O estudo emprega um conjunto de dados baseado no dataset HAM 10000, contendo 10.015 imagens, selecionando uma parcela do conjunto e aplicando o método de aumento de dados.

Outros entendimentos do tema estão em trabalhos como "*Machine Learning and Its Application in Skin Cancer*", "*Multimodal skin lesion classification using deep learning*", "*Deep Convolutional Neural Network with TensorFlow and Keras to Classify Skin Cancer Images*", "*Skin lesion classification of dermoscopic images using machine learning and convolutional neural network*" ao qual disponibilizam do uso de grandes conjunto de dados como HAM10000 e ISIC.

Quanto a estes, utilizam de uma rede pré-treinada capaz de suprir as dificuldades de detecção e classificação de lesões de pele através de suas características, fornecendo uma precisão variável entre 63.6% até 95.18% e demonstram resultados significativos com os dados de teste, além de exemplificar a capacidade dos modelos utilizados em todos esses trabalhos.

Tabela 1. Trabalhos Correlatos

Autores	Trabalhos Correlatos	Datasets	Rede Neural	Causa/Problema	Precisão
Das et al., 2021	Machine Learning and Its Application in Skin Cancer	HAM10000, BCN20000, PH2 Dataset	ResNet50	Câncer de pele	76.5%
Hu et al., 2021	TopoResNet: A Hybrid Deep Learning Architecture and Its Application to Skin Lesion Classification	HAM10000, ISIC	TopoResNet-101	Classificação das Lesões de Pele	63.6%
Kassem et al., 2021	Machine Learning and Deep Learning Methods for Skin Lesion Classification and Diagnosis: A Systematic Review	MedNode, ISIC, PH2 Dataset	ResNet50 / ResNet101 / AlexNet / VGG	Classificação das Lesões de Pele	75-84%
Yap et al., 2023	Multimodal skin lesion classification using deep learning	ISIC 2017	ResNet50	Classificação das Lesões de Pele	85%
Yaqoob et al., 2021	ResNet Based Deep Features and Random Forest Classifier for Diabetic Retinopathy Detection	Messidor-2	ResNet50	Deteção de Retinopatia Diabética	96%
Benbrahim et al., 2023	Deep Convolutional Neural Network with TensorFlow and Keras to Classify Skin Cancer Images	HAM10000	TensorFlow & Keras	Deteção de câncer de pele	93.93%
Shetty et al., 2022	Skin lesion classification of dermoscopic images using machine learning and convolutional neural network	HAM10000	ResNet50	Deteção de câncer de pele	95.18%

2.1 REDES NEURAIS PROFUNDAS

Redes neurais são um tipo de algoritmo de aprendizado de máquina inspirado na estrutura e funcionamento do cérebro humano. Elas são compostas por camadas de neurônios que processam informações e aprendem a identificar padrões em grandes quantidades de dados.

Em dermatologia, as redes neurais podem ser aplicadas na análise de imagens de lesões de pele para auxiliar na detecção precoce de melanoma e outras condições. Deste modo, a aplicação de técnicas de inteligência artificial, especialmente redes neurais profundas e redes pré-treinadas, podem auxiliar na detecção e entendimento do melanoma em seus pacientes.

Quando nos referimos a *Deep Learning* (Redes Neurais Profundas), segundo Russell e Norvig (2022), redes neurais profundas são modelos de aprendizado de máquina que são inspirados na estrutura do cérebro humano e são projetadas para aprender representações complexas e hierárquicas dos dados, juntamente a modelos pré-treinados aos quais visam realizar uma tarefa em um grande conjunto de dados.

Outra aplicação das redes neurais profundas na dermatologia é na diferenciação de melanomas de outras lesões benignas, como nevos. Em um estudo publicado na revista "*Scientific Reports*" por Abbasi et al. (2021), os pesquisadores treinaram uma rede neural para distinguir melanomas de nevos usando imagens de lesões de pele. A rede neural alcançou um desempenho superior ao de dermatologistas em identificar corretamente melanomas e nevos.

Embora as redes neurais apresentem um grande potencial para auxiliar os dermatologistas na detecção e diferenciação de melanomas, é importante destacar que elas não substituem a avaliação clínica e histopatológica realizada pelos dermatologistas. Elas são ferramentas complementares que podem auxiliar na tomada de decisão e reduzir o tempo de espera para o diagnóstico.




Figura 1. Rede Neural Profunda (*Deep Learning*) Adaptado

A Figura 1 demonstra a arquitetura de uma rede neural profunda, sendo Conv1, Conv2, Conv3, Conv4 e Conv5 suas camadas que aplicam filtros para extração das características. A função ReLu (*Rectified Linear Unit*) é aplicada após cada Conv para introduzir não-linearidade no modelo, o *Max Pooling* é usado para reduzir a dimensionalidade e extrair características dominantes, tornando a representação mais manejável. A última camada é uma camada de *softmax*, transformando os valores de saída em probabilidades, onde a soma de todas é igual a 1.

2.2 REDE NEURAL CONVOLUCIONAL

Uma arquitetura de rede neural convolucional (CNN) é um modelo de aprendizado profundo usado para processar dados com estrutura espacial, como imagens. Ela consiste em múltiplas camadas ocultas, que são diferentes no tipo e na sua conectividade Benbrahim et al. (2023). As camadas ocultas começam com a camada de convolução, em que filtros são aplicados à entrada para extrair características relevantes. Em seguida, há camadas de ativação e pooling, que introduzem não-linearidade e reduzem a dimensionalidade dos dados.

As CNNs são capazes de aprender características de imagens de maneira hierárquica, com as primeiras camadas aprendendo características simples, como bordas e cantos, e as camadas posteriores aprendendo características mais complexas LeCun et al. (1998), como formas e texturas. Essa capacidade permite que as CNNs identifiquem objetos mesmo quando eles estão parcialmente obscurecidos ou em diferentes poses.

As CNNs têm sido amplamente aplicadas em diversas áreas, como visão computacional, reconhecimento de fala e processamento de texto, devido à sua capacidade de extrair e interpretar informações espaciais de maneira eficiente. No entanto, essa capacidade pode ser limitada por ruídos e distorções nos dados de entrada, o que pode levar a erros na identificação de objetos ou na classificação de dados.

Em resumo, a CNN é uma ferramenta essencial para o aprendizado profundo, pois são capazes de interpretar e extrair informações complexas a partir de dados estruturados espacialmente. O contínuo desenvolvimento e aplicação das CNNs em diferentes domínios demonstram a sua relevância e impacto na vanguarda da inteligência artificial.

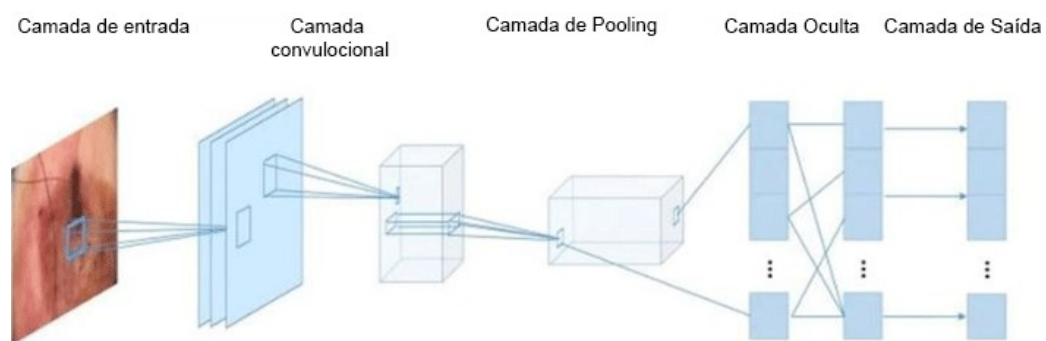


Figura 2. Processo de uma Rede Neural Convolucional para classificação de imagens

2.3 TRANSFER LEARNING

Transfer learning, ou aprendizado por transferência, é uma técnica em aprendizado de máquina que consiste em aproveitar o conhecimento adquirido por uma rede neural pré-treinada em uma tarefa e aplicá-la em uma tarefa relacionada ou similar. Essa técnica é particularmente útil quando se tem um pequeno conjunto de dados para a nova tarefa, pois permite que a rede neural comece o treinamento com um ponto de partida mais avançado, o que pode levar a um melhor desempenho e a um treinamento mais rápido.

A ideia principal do *transfer learning* é que as características aprendidas por uma rede neural pré-treinada em um grande conjunto de dados geralmente são úteis e transferíveis para outras tarefas. Por exemplo, uma rede neural pré-treinada para a tarefa de classificação de imagens de gatos e cachorros pode ser usada como ponto de partida para uma rede neural para a tarefa de classificação de imagens de animais de estimação. As vantagens do *transfer learning* incluem: melhor desempenho com menos dados, treinamento mais rápido e transferência de conhecimento.

Em um estudo recente, Ibrahem Kandel et al. (2020) investigaram a aplicação do *transfer learning* para classificação de imagens de retinopatia diabética. Os autores mostraram que o *transfer learning* é eficaz para a criação de novas redes neurais convolucionais (CNNs), mesmo com pequenos conjuntos de dados. Os autores também apontam quatro estratégias para utilização do *transfer learning*: congelamento de pesos, descongelamento parcial, descongelamento total e transferência de conhecimento.




Figura 3. Funcionamento do Transfer Learning

2.4 ARQUITETURA RESNET

A ResNet-50, é uma arquitetura de rede neural convolucional (*Convolutional Neural Network*) pré-treinada com 50 camadas, sendo amplamente utilizada como uma poderosa ferramenta de extração de características em tarefas de visão computacional. Uma abordagem eficiente para aproveitar sua capacidade é aplicar a transferência de aprendizado (*Transfer learning*), iniciando o modelo com os pesos pré-treinados em conjuntos de dados. Essa inicialização fornece ao modelo uma base sólida de conhecimento visual, acelerando o processo de treinamento e resolvendo problemas de desvanecimento do gradiente, permitindo o treinamento de redes profundas.

Além disso, a ResNet-50 apresenta benefícios como melhor desempenho, geração de representações ricas e hierárquicas, e a possibilidade de reutilização de arquiteturas pré-treinadas. Essa abordagem tem se mostrado altamente qualificada e capaz de alcançar resultados notáveis em diversas tarefas, como demonstrado no estudo de Yaqoob, MK. et al (2021), no qual a ResNet-50 foi utilizada para o reconhecimento e análise de retinopatia diabética. Os autores do estudo obtiveram resultados promissores, com uma taxa de precisão de 96%.

No geral, a arquitetura ResNet se destaca por sua capacidade de lidar com redes neurais profundas e superar desafios como o desvanecimento do gradiente. Com suas vantagens em desempenho e capacidade de aprendizado de representações complexas, a ResNet é amplamente utilizada e referenciada na área de visão computacional.




Figura 4. Arquitetura ResNet-50 (Adaptada)

A arquitetura básica de uma ResNet é apresentada na Figura 4. É aplicada na entrada um bloco de preenchimento zero. No estágio 1, a Convolução 2D tem 64 filtros e usa uma *stride*, além da utilização do *Pooling* sendo responsável pela operação de dimensionalidade e redução de ruídos, usando uma matriz 2 por 2. Os estágios 2, 3, 4, 5 são compostos por três blocos de convolução, a primeira camada de cada bloco é responsável por aprender as características locais da imagem, já a segunda camada pelas características globais, levando em consideração, cada estágio é responsável por extrair características ainda mais complexas.

Por fim, o *Average Pooling* reduz o tamanho da imagem e a representa através de uma matriz, em seguida é utilizado *Flattening* para converter a representação matricial em uma representação vetorial e, por último faz uso de uma rede neural densa para mapear o vetor para a saída desejada.

3. PROCEDIMENTOS METODOLÓGICOS

A figura 5 demonstra as fases para o desenvolvimento do projeto onde foram definidas etapas que passam desde seu início com a escolha de um conjunto de dados adequado até a avaliação final do modelo. Com a utilização do *Keras* sendo executada no *TensorFlow* houve a capacidade de realizar o processamento das imagens, agrupando corretamente e exemplificando suas sete classes.

Para implementação do projeto foi designado o conjunto de dados HAM10000, disponibilizada por Harvard, devido a seu grande volume de dados acaba sendo um auxiliador inicial para construção de modelos de análise para detecção e classificação de doenças pele.

O conjunto de dados passou por etapas de pré-processamento para garantir a sua integridade e confirmar sua validação para o uso, sendo separadas com valores de 70% para treinamento do modelo, 20% para testes e 10% para validação.

Visando um modelo capaz de classificar doenças de pele, a arquitetura ResNet-50 demonstra grande eficiência neste ambiente, sendo capaz de atuar em projetos envolvendo visão computacional, devido a sua troca de informação entre camadas, gerando menor taxa de erros.

Com a utilização de um modelo tabular e o modelo baseado na ResNet 50 utilizando *Transfer Learning*, há uma concatenação através de bibliotecas gerando um modelo final que determina a precisão de acurácia das classes.

Por fim, sucedeu-se uma avaliação dermatológica verbal do modelo indicando seus prós e contras e sua utilização para fins de desenvolvimento na área, além de conhecimentos voltados para inteligência artificial e sua finalidade e importância para a área da saúde.




Figura 5. Fases de implementação do projeto

3.1 DADOS

A abordagem técnica ideal para criar um algoritmo que classifica imagens pode ser dividida em vários passos, podemos citar como uma das principais a escolha e extração de um conjunto de dados e o tratamento dos mesmos para poder manter em nosso espectro de análise somente dados interessantes e íntegros.

É necessário realizar a escolha do conjunto, neste aspecto foram selecionados grandes bancos para execução das comparações, sendo eles: HAM10000 e ISIC, aos quais fornecem mais de dez mil imagens de lesões de peles e possuem metadados relevantes aos quais estão associados ao gênero, faixa etária, localização da lesão na região do corpo.

O projeto apresenta sete classes distintas de doenças de pele as quais devem ser detectadas e categorizadas pelo modelo através de suas características (tamanho,

formato e coloração). As classes presentes são:

A queratose actínica, é uma área pré-cancerosa da pele que é espessa, escamosa ou com crostas. Ela surge da exposição prolongada aos raios ultravioleta (UV) do sol. A queratose actínica é considerada uma condição pré-cancerosa porque, se não for tratada, pode se desenvolver em carcinoma de células escamosas, um tipo de câncer de pele.



Figura 5. Queratoses actínicas

O carcinoma de células basais (CCB) é o tipo mais comum de câncer de pele. Ele se origina das células basais, que estão localizadas na parte inferior da epiderme, a camada mais externa da pele. O carcinoma de células basais geralmente ocorre em áreas da pele que foram expostas ao sol.



Figura 6. carcinoma de células basais

Lesões benignas semelhantes a ceratose referem-se a um grupo de condições cutâneas não cancerígenas (benignas), mas que compartilham algumas características com a ceratose, que é o espessamento da camada externa da pele (epiderme). Essas lesões frequentemente envolvem o crescimento anormal de ceratinócitos, o tipo predominante de célula na epiderme.




Figura 7. Lesões benignas semelhantes a ceratose

O dermatofibroma é uma lesão cutânea benigna que se desenvolve na pele. Essas lesões são comuns e geralmente aparecem como pequenos nódulos ou protuberâncias na pele. Elas são mais frequentemente encontradas nas pernas, mas também podem ocorrer em outras partes do corpo.



Figura 8. Dermatofibroma

O melanoma é um tipo de câncer de pele que se desenvolve a partir das células produtoras de melanina, chamadas melanócitos. A melanina é o pigmento responsável pela cor da pele, cabelo e olhos. O melanoma é considerado o tipo mais perigoso de câncer de pele devido à sua capacidade de se espalhar rapidamente para outras partes do corpo, tornando-se potencialmente letal.




Figura 9. Melanoma

Nevos melanocíticos, comumente conhecidos como pintas, são crescimentos benignos (não cancerosos) na pele que se desenvolvem quando os melanócitos, as células produtoras de pigmento na pele, se agrupam. Essas células são responsáveis por dar cor à pele.



Figura 10. Nevos melanocíticos

Lesões vasculares referem-se a anormalidades nos vasos sanguíneos. Elas podem ocorrer em várias partes do corpo e podem envolver artérias, veias ou capilares. Existem diferentes tipos de lesões vasculares, e podem ser congênitas (presentes ao nascimento) ou adquiridas (desenvolvidas mais tarde na vida).



Figura 11. Lesões vasculares

3.2 ARQUITETURAS

Visando um melhor desempenho e acurácia, o modelo ResNet-50 se destaca pela sua capacidade de aprendizado, sua utilização como base demonstra vantagens em diversos pontos. Em primeiro lugar, a adição de camadas densas implementada no modelo demonstra uma maior capacidade de compartilhamento de dados entre os neurônios da rede e uma aptidão para resolução de problemas complexos, potencializando a detecção de doenças de pele de uma maneira mais precisa e revolucionando o diagnóstico de doenças de pele.

Na arquitetura CNN foram adicionadas camadas separadamente, sendo a primeira, uma divisão de filtros para a transformação de imagens, a segunda sendo voltada ao pooling para redução da resolução, a utilização de *Dropout* para redução de *overfitting*, uma camada *Flatten* para nivelamento e camadas densas.




Figura 12. Arquitetura CNN contendo uma entrada, processamento de dados e resultados. (Adaptada)

Com a utilização destas duas arquiteturas há uma concatenação dos modelos através da biblioteca ‘fastai’ disponibilizada pelo *PyTorch*, realizando a junção da arquitetura CNN (modelo tabular) juntamente ao ResNet-50, tornando-se um modelo de avaliação de precisão na detecção e classificação das classes presentes.

3.3 METADADOS

O artigo “*Metadata Demystified*” publicado por Amy Brand et al (2003) apresenta o conceito de metadados como informações sobre informações, ou dados sobre dados. Descrevem conhecimentos sobre processos, potencializando e permitindo que os usuários tenham vantagens sobre o caso. Sendo uma ferramenta essencial para a gestão de informações e utilizados para aperfeiçoamento de eficiência, segurança e confiabilidade em meios que utilizam de suas aplicações.

A geração de um modelo final através da concatenação do modelo pré-treinado ResNet-50 com o modelo tabular permite a identificação de informações relevantes, sucedeu-se uma adição de metadados através da biblioteca “fastai” para relatar informações adicionais sobre a lesão de pele, como faixa etária, gênero e local da lesão.

Demonstrou ser uma ferramenta valiosa para identificação de lesões difíceis de distinguir em imagens. Além disso, essa abordagem garante que o conjunto de dados contenha todas as informações necessárias para uma detecção e classificação precisas, bem como o reconhecimento de padrões comuns a determinados grupos de imagens.




Figura 13. Diagrama de arquitetura ResNet 50 (Adaptada)

A figura 7 demonstra a utilização dos metadados atrelado a utilização da arquitetura ResNet-50 através da concatenação do modelo tabular. Inicialmente, o modelo ResNet recebe uma entrada do conjunto de dados e faz o pré-processamento da imagem e utiliza dos metadados para um entendimento maior da lesão, chegando a um resultado.

4. RESULTADOS

A implementação do método proposto na classificação de imagens de lesões cutâneas resultou em uma precisão de 78%, indicando sua objetividade na identificação e classificação correta das classes e figuras. A concatenação dos metadados com as imagens classificadas reduziu a acurácia para 68%, o que não é considerado um resultado negativo. Ao considerar o projeto como um todo, mesmo com a redução da acurácia, esta ainda é considerada alta, devido à grande quantidade de classes e metadados.

Na tabela 2 há os resultados obtidos durante a fase de teste do modelo.

Tabela 2. Tabela dos Resultados obtidos durante os testes do modelo sem metadados com o ResNet-50

Classes	Precision	Recall	F1-Score	Support
Melanocytic_nevi	0.44	0.33	0.38	33
Melanoma	0.46	0.36	0.41	33
Benigh_keratosi_s_like_lesions	0.53	0.63	0.58	11
Basal_cell_carcinoma	0.40	0.17	0.24	12
Actinic_keratosis	0.88	0.93	0.90	670
Vascular_lesions	0.60	0.39	0.48	112
Dermatofibroma	0.54	0.47	0.50	15
Accuracy			0.78	986
Macro avg	0.55	0.47	0.50	986
Weighted avg	0.77	0.78	0.77	986

Na tabela 2, a *Precision* nos diz qual proporção dos casos identificados como positivos pelo modelo realmente são positivos, ou seja, quão preciso ele é, o *Recall* nos diz qual proporção dos casos positivos reais o modelo identifica corretamente, ou seja, sua habilidade em não perder nenhum caso positivo. Por fim, o *F1-score* é uma média que equilibra recall e precisão, sendo útil quando há um desequilíbrio entre as classes e o *Support* fornece o contexto de distribuição das classes no conjunto de dados.

Levando em consideração outros fatores além da acurácia, o modelo apresenta um Macro AVG (Média Macro) de 55%, sendo responsável por calcular a média de desempenho das classes individualmente. Neste quesito, demonstra uma instabilidade ao qual algumas classes estão performando melhor que outras.

A Weighted AVG (Média Ponderada) leva em consideração o balanceamento das classes, demonstrando que as maiores métricas representam um peso maior na média. Tendo um resultado de 77% determina que o modelo se desempenha bem em classes mais frequentes, todavia, em classes menos representadas a precisão não se sai tão bem como o esperado.

Apesar da tabela apresentar um percentual de resultado relevante, acaba não demonstrando um indicador de desempenho real, visto que em contextos médicos há custos associados aos falsos positivos ou negativos podendo alterar significativamente os valores em virtude de possíveis erros de identificação por parte do modelo.

Apesar da tabela apresentar um percentual de resultado relevante não é um indicador de desempenho real, a figura 8 demonstra falsos positivos ou negativos, visto que em conceitos médicos esses resultados podem alterar significativamente os valores obtidos pelo modelo.

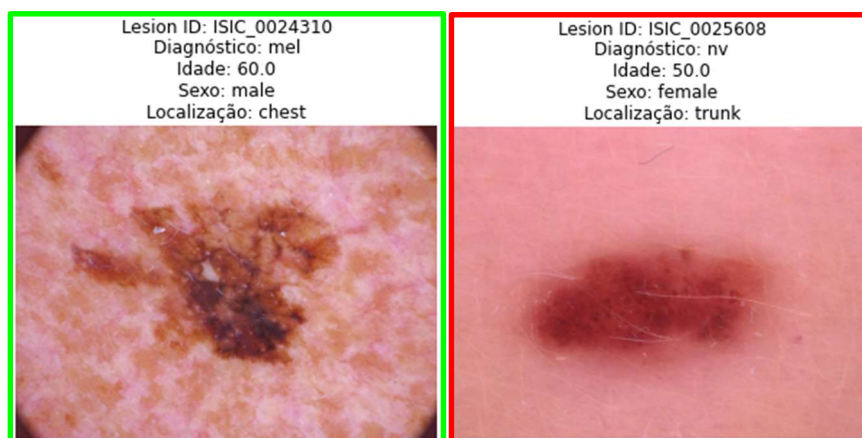


Figura 14. Melanoma em verde representa acerto e em vermelho falso positivo ou negativo.

4.1 COMPARATIVO DE RESULTADOS

Um modelo pré-treinado ResNet é conhecido por sua capacidade de aprender representações profundas, superando o problema de degradação do desempenho à medida que a rede se torna mais profunda. Com sua estrutura de conexões residuais, consegue resolver esse problema e obter resultados significativos em tarefas de

classificação.

Além disso, um modelo CNN comum usando técnicas convencionais de aprendizado de máquina é utilizado, servindo como base para concatenação dos modelos e avaliar o desempenho da ResNet. Ambos os modelos foram treinados e testados no dataset HAM10000, usando uma divisão adequada dos dados em conjuntos de treinamento e teste.

Tendo em vista os resultados de ambos os modelos, sucedeu-se uma comparação em termos de desempenho e precisão, ao qual estão atreladas a avaliação da eficácia de cada modelo para a classificação de diferentes classes de diagnósticos presentes no conjunto de dados.

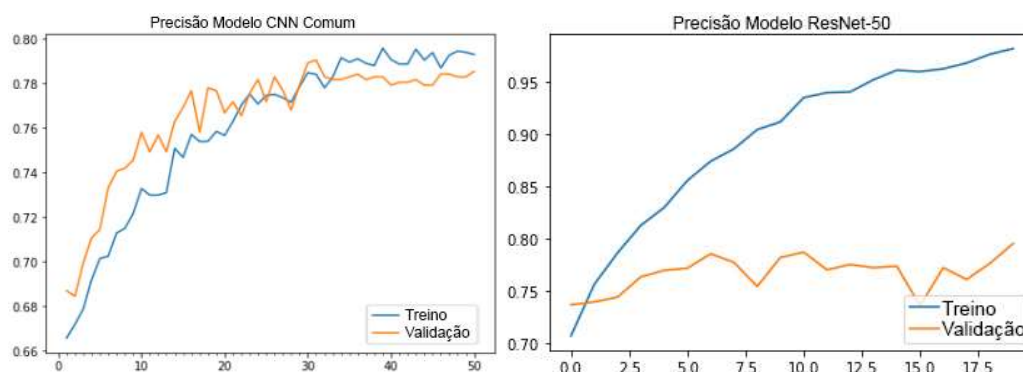


Figura 15. Gráfico curva de acurácia do modelo CNN Comum comparado ao modelo do projeto utilizando a arquitetura ResNet-50 como base.

Ao observar os quocientes de acurácia apresentados na figura 9, a curva de aprendizado do modelo CNN comum apresenta escalabilidade até 0.77, obtendo uma precisão de 77.03% com 50 épocas, demonstrando ser um modelo eficiente e capaz de suprir as falhas apresentadas pelo olho humano

O modelo desenvolvido com o ResNet-50, alcança algo semelhante a este resultado. Devido à sua capacidade de aprendizado profundo e à extração de características mais abstratas e relevantes juntamente a concatenação dos metadados no modelo e 17.5 épocas há uma acurácia de 68%, enquanto, sem a presença de metadados há um limite de validação dos testes em 0.78 apresentado na figura 9, demonstrando uma precisão de 78% tornando-se muito semelhante ao modelo comum em quesito de solução.

Portanto, com os resultados demonstrados e levando em consideração a implementação dos metadados, o modelo CNN Comum apresenta uma taxa de acuracidade maior, enquanto o modelo final se torna recomendado para uso dermatológico e tratamentos preventivos com suas informações adicionais, podendo alertar quando há um risco maior ou menor de agravação da lesão.

5. CONCLUSÃO

Em geral, os resultados obtidos em ambos os modelos apresentam números satisfatórios demonstrando suas eficiências em diagnosticar e classificar os tipos de doenças de pele, quanto ao ResNet-50, tratando-se de um modelo mais complexo, há benefícios significativos em relação ao modelo convencional, disponibilizando de

insights valiosos para imagens dermatológicas devido a implementação dos metadados junto ao modelo e uma melhor contribuição no avanço da detecção precoce e diagnóstico de doenças de pele.

A implementação de um modelo final com metadados através da concatenação disponibilizou um resultado compreensivo, além de demonstrar informações importantes aos quais agregam na avaliação da lesão e detecta características fundamentais para diferenciação de classes, fornecendo uma avaliação mais precisa para análises dermatológicas.

Quanto ao acesso e visualização do modelo, é possível acessá-lo através da plataforma GitHub¹, sendo disponibilizado para interação, visualização e realização de futuras melhorias no código, além de sua adaptação para novos projetos voltados ao mesmo meio.

Dado o modelo, um profissional responsável pelo tratamento de doenças de pele demonstra uma satisfação e admiração, em sua opinião, a utilização de inteligência artificial no meio da saúde se torna cada vez mais uma realidade. A utilização de um modelo capaz de distinguir e classificar classes de doenças de pele se torna algo útil principalmente para futuros profissionais em formação, aos quais necessitam se atualizar sobre as diferenças de características de cada doença.

Quanto aos seus prós, foram citados diversos pontos, aos quais estão voltados para o avanço da área da medicina e auxílio na detecção caso haja uma dúvida por parte do profissional, e quanto a seus contras, o fato da detecção precoce de um provável câncer foi exaltado, podendo causar um impacto psicológico ao paciente.

Um ponto a destacar é o possível aumento da acurácia do modelo se dando pela desigualdade de proporção de classes, demonstrando que a questões de longo prazo há espaço para melhorias e para implementação de novas ferramentas capazes de produzir uma melhor acurácia e precisão na detecção de classes e classificação de lesões.

Para abordagens futuras podemos trabalhar com um conjunto de dados mais volumosos e melhorar os parâmetro e técnicas de treinamento para gerar um modelo final que tenha uma assertividade maior e com isso aumentar a aplicabilidade do nosso modelo.

6. REFERÊNCIAS

MACHINE Learning and Its Application in Skin Cancer. International Journal of Environmental Research and Public Health, [S. l.], p. 1-10, 18 dez. 2021.
Disponível em: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8705277/>.
Acesso em: 8 dez. 2023.

¹ https://github.com/Gaazedo/Concat_Model/

TOPORESNET: A Hybrid Deep Learning Architecture and Its Application to Skin Lesion Classification. *Mathematics*, [S. l.], v. 9, 22 set. 2021. Disponível em: <https://www.mdpi.com/2227-7390/9/22/2924>. Acesso em: 8 dez. 2023.

MACHINE Learning and Deep Learning Methods for Skin Lesion Classification and Diagnosis: A Systematic Review. *Diagnostics*, [S. l.], v. 11, p. 1-29, 8 nov. 2021. Disponível em: <https://www.mdpi.com/2075-4418/11/8/1390>. Acesso em: 8 dez. 2023.

MULTIMODAL skin lesion classification using deep learning. *Experimental Dermatology*, [S. l.], p. 1-7, 27 nov. 2018. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/30187575/>. Acesso em: 9 dez. 2023.

RESNET Based Deep Features and Random Forest Classifier for Diabetic Retinopathy Detection. *Sensors*, [S. l.], v. 21, p. 1-14, 5 abr. 2021. Disponível em: <https://www.mdpi.com/1424-8220/21/11/3883>. Acesso em: 9 dez. 2023.

DEEP Convolutional Neural Network with TensorFlow and Keras to Classify Skin Cancer Images. *Scalable Computing: Practice and Experience*, [S. l.], v. 21, p. 379–389, 1 ago. 2020. Disponível em: <https://www.scpe.org/index.php/scpe/article/view/1725>. Acesso em: 9 dez. 2023.

SKIN lesion classification of dermoscopic images using machine learning and convolutional neural network. *Scientific Reports*, [S. l.], v. 12, p. 1-11, 28 out. 2022. Disponível em: <https://www.nature.com/articles/s41598-022-22644-9>. Acesso em: 9 dez. 2023.

GRADIENT-BASED learning applied to document recognition. *Proceedings of the IEEE*, [S. l.], v. 86, n. 11, p. 2278-2324, 10 nov. 1998. Disponível em: <https://ieeexplore.ieee.org/document/726791>. Acesso em: 9 dez. 2023.

TRANSFER Learning with Convolutional Neural Networks for Diabetic Retinopathy Image Classification. A Review. *Applied Sciences*, [S. l.], v. 10, p. 6, 16 mar. 2020. Disponível em: <https://www.mdpi.com/2076-3417/10/6/2021>. Acesso em: 9 dez. 2023.

ARTIFICIAL Intelligence: A Modern Approach. Book, [S. l.], p. 1-1152, 25 maio

1995.

ESTIMATIVA: Incidência de Câncer no Brasil. Ministério da Saúde Instituto Nacional de Câncer, [S. l.], p. 1-162, 13 dez. 2022. Disponível em: <https://www.inca.gov.br/sites/ufu.sti.inca.local/files/media/document/estimativa-2023.pdf>. Acesso em: 8 nov. 2023.

METADATA Demystified: A Guide for Publishers. The Sheridan Press, [S. l.], p. 1-19, 1 jan. 2003. Disponível em: <https://www.niso.org/publications/metadata-demystified-guide-publishers>. Acesso em: 9 dez. 2023.

ACTINIC keratosis: a clinical and epidemiological revision. Anais Brasileiros de Dermatologia, [S. l.], p. 1-10, 3 jun. 2012. Disponível em: <https://www.scielo.br/j/abd/a/PwJtf7XHVBpJSN9j7FVnLmH/?format=html&lang=en>. Acesso em: 9 dez. 2023.